

# **Лекция 1. Методология CRISP-DM. Начало работы над ML-проектом**

Практикум по программированию, 5 семестр

Иван Евгеньевич Бугаенко,  
ассистент каф. ПМИФИ

# Цель курса

**Основная цель** – научиться работать с ML-проектами и строить обоснованные модели на основе аналитики данных

- принятие решений на основе статистического и графического анализа данных и аргументация своих действий
- обоснование выбора методов предобработки данных и моделей для прогнозирования
- интерпретирование работы модели
- применение современных методов анализа данных и лучших практик

# Формат работы

Курс состоит из:

- 5+4 лекционных занятий (10 баллов)
- 5 лабораторных работ (50 баллов)
- домашнего задания (10 баллов)
- демозамена (30 баллов)

---

**Итого: 100 баллов**


Все материалы выкладываются на [wiki.pmifi.ru](https://wiki.pmifi.ru)

Рейтинг ведется в [таблице](#)

Зачем нужно обосновывать свои  
решения в ML?


Итоговая цель каждого ML-проекта –  
разработать жизнеспособную модель

Как вы себе представляете работу над ML-проектом?




натывать наугад

# Как вы себе представляете работу над ML-проектом?




натыкать наугад




перебрать все  
варианты

# Как вы себе представляете работу над ML-проектом?



натыкать наугад



перебрать все  
варианты



обоснованный пайплайн  
работы с данными

# Проблемы других подходов

- невозможно перебрать ВСЕ варианты
- шаги по работе с данными могут совершаться интуитивно и наугад, что может испортить качество модели
- нет обоснования, почему были совершены те или иные действия, что затрудняет читаемость работы и ее воспроизводимость

# Проблемы других подходов

- невозможно перебрать ВСЕ варианты
  - шаги по работе с данными могут совершаться интуитивно и наугад, что может испортить качество модели
  - нет обоснования, почему были совершены те или иные действия, что затрудняет читаемость работы и ее воспроизводимость
- 

**Работа становится одним большим черным ящиком!  
Итоговой модели нельзя доверять**

# Что такое аналитика данных?

**Аналитика данных** – это набор подходов и инструментов по извлечению информации из данных, которая используется для обоснования шагов, которые совершаются в ходе решения ML-задачи


Обосновывая свои шаги, исследователь  
получает жизнеспособную, надежную и  
понимаемую модель

# Жизненный цикл ML-проекта

**CRISP-DM** (Cross-Industry Standard Process for Data Mining) – это стандартная методология жизненного цикла проектов по анализу данных и машинному обучению, которая описывает последовательность шагов от постановки бизнес-задачи до внедрения готового решения

# Этапы CRISP-DM

| Business Understanding                                                                                                                                                                 | Data Understanding                                                       | Data Preparation                                                         | Modeling                                                                                    | Evaluation                                                                                                                           | Deployment                                                                           |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------|--------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| <b>Determine Business Objectives</b><br><i>Background<br/>Business Objectives<br/>Business Success<br/>Criteria</i>                                                                    | <b>Collect Initial Data</b><br><i>Initial Data Collection<br/>Report</i> | <b>Select Data</b><br><i>Rationale for Inclusion/<br/>Exclusion</i>      | <b>Select Modeling Techniques</b><br><i>Modeling Technique<br/>Modeling<br/>Assumptions</i> | <b>Evaluate Results</b><br><i>Assessment of Data<br/>Mining Results w.r.t.<br/>Business Success<br/>Criteria<br/>Approved Models</i> | <b>Plan Deployment</b><br><i>Deployment Plan</i>                                     |
| <b>Assess Situation</b><br><i>Inventory of Resources<br/>Requirements,<br/>Assumptions, and<br/>Constraints<br/>Risks and<br/>Contingencies<br/>Terminology<br/>Costs and Benefits</i> | <b>Describe Data</b><br><i>Data Description<br/>Report</i>               | <b>Clean Data</b><br><i>Data Cleaning Report</i>                         | <b>Generate Test Design</b><br><i>Test Design</i>                                           | <b>Review Process</b><br><i>Review of Process</i>                                                                                    | <b>Plan Monitoring and Maintenance</b><br><i>Monitoring and<br/>Maintenance Plan</i> |
| <b>Determine Data Mining Goals</b><br><i>Data Mining Goals<br/>Data Mining Success<br/>Criteria</i>                                                                                    | <b>Explore Data</b><br><i>Data Exploration<br/>Report</i>                | <b>Construct Data</b><br><i>Derived Attributes<br/>Generated Records</i> | <b>Build Model</b><br><i>Parameter Settings<br/>Models<br/>Model Descriptions</i>           | <b>Determine Next Steps</b><br><i>List of Possible Actions<br/>Decision</i>                                                          | <b>Produce Final Report</b><br><i>Final Report<br/>Final Presentation</i>            |
| <b>Produce Project Plan</b><br><i>Project Plan<br/>Initial Assessment of<br/>Tools and<br/>Techniques</i>                                                                              | <b>Verify Data Quality</b><br><i>Data Quality Report</i>                 | <b>Integrate Data</b><br><i>Merged Data</i>                              | <b>Assess Model</b><br><i>Model Assessment<br/>Revised Parameter<br/>Settings</i>           | <b>Review Project</b><br><i>Experience<br/>Documentation</i>                                                                         |                                                                                      |
|                                                                                                                                                                                        |                                                                          | <b>Format Data</b><br><i>Reformatted Data</i>                            |                                                                                             |                                                                                                                                      |                                                                                      |
|                                                                                                                                                                                        |                                                                          | <i>Dataset<br/>Dataset Description</i>                                   |                                                                                             |                                                                                                                                      |                                                                                      |



Можно ли шаблонизировать ML-проект?

Каждая ML-задача уникальна, однако можно выделить базовый пайплайн по обработке данных с учетом CRISP-DM

# Основные шаги по работе с ML-проектом

1. Описание задачи и признаков (Business & Data Understanding)
2. Предварительная обработка данных (Data Preparation)
3. Генерация новых признаков (Data Preparation)
4. Выбор ML-моделей и метрик качества (Modeling)
5. Обучение моделей, кросс-валидация и подбор гиперпараметров (Modeling)
6. Получение предсказаний на новых данных и вычисление метрик (Evaluation)

# Шаг 0. Описание задачи и признаков

На данном шаге исследователь собирает всю входную информацию о проекте:

- формулирует постановку задачи
- выполняет описание признакового пространства (определяет входные и целевые признаки, ограничения на значения, выписывает зависимости прикладной области)
- формирует виртуальное окружение (импорт библиотек, seed, фиксация версий библиотек для работы)
- + в самом конце – содержание работы (table of content)

**Цель:** сделать так, чтобы читатель понял, для чего решается задача, какая это вообще задача, а также чтобы работа была воспроизводима (можно было ее запустить с теми же параметрами)

# Шаг 1. Предварительная обработка данных

На данном шаге исследователь выполняет базовые действия по работе с данными:

- загружает данные в рабочее пространство, выводит их и приводит признаки к необходимому типу (+ агрегация, парсинг дат, отбрасывание столбцов) – первичный этап обработки данных
- разделяет выборку на обучение и тест
- обрабатывает пропущенные значения
- выполняет кодировку категориальных признаков
- решает проблему наличия выбросов и аномалий в данных
- устраняет дисбаланс классов (для задачи классификации)

**Цель:** обработать данные так, чтобы можно было обучить baseline-модель

Baseline-модель – это такая наивная модель ML, которая обучалась на базовом варианте обработанных данных. Используется для проверки эффективности инструментов предобработки

# Советы по начальному этапу обработки датасета

- всегда обращайте внимание на кодировку файла с данными и на разделитель (если речь про .csv и .tsv файлы)
- если датасет содержит даты, то передавайте их в параметр `parse_dates`
- обязательно выводите фрагмент датасета через `DataFrame.head()`, чтобы убедиться, что все корректно почиталось
- анализируйте при помощи `DataFrame.info()`, корректно ли парсятся типы данных при загрузке датасета (сверяйтесь с табличкой, содержащей инфу о семантике признаков); если типы не соответствуют, выполняйте ручное приведение
- для принятия решения об отбрасывании категориального признака смотрите на его семантику и количество уникальных значений (`Series.nunique()`)
- обращайте внимание на признаки, которые неизвестны на момент получения прогноза, они подлежат удалению

# Советы по начальному этапу обработки датасета

- агрегаты данных разбивайте на компоненты, если это не критично для задачи (например, дату можно разбить на день, месяц и год, если не решается задача анализа временных рядов)
- контролируйте, чтобы во входных признаках не было утечки данных

# Типичные ошибки при делении выборки на train/test

- допускается утечка информации → рекомендуется сначала выполнять деление выборки, а потом выполнять действия только с train-датасетом (и результаты переносить на test)
- игнорируется временная структура данных → нужно контролировать, чтобы данные о "будущем" не попадали в обучающую выборку
- нарушение баланса классов → использовать стратификацию выборки при разделении (например, поле stratify=...)
- слишком большой/маленький train/test → контролировать объем выборки